

思考了 15m 7s >

当前会话没有暴露可编排的独立子代理接口，因此我不能声称实际启动了多个独立模型实例。为避免伪造调研过程，下面按 **六个相互独立的审查角色** 完成多轮调研与红队审查：

1. AHD 文献与新颖性审查；
2. LLM 后训练与 GRPO 机制审查；
3. 因果、统计与实验有效性审查；
4. 方法设计与复杂度审查；
5. 系统成本、泛化与复用审查；
6. AAAI 审稿人视角的最终红队审查。

这轮审查后，结论比此前更收敛：

此前“信号分解 + contrastive reward + operator scheduling + SFT/curriculum/reuse”的宽方案仍然过重。冲击 AAAI 最合理的主线应进一步缩小为：一个核心现象，加一个核心方法。

核心现象：

Validity-mediated search amplification：在线 RL 可能主要提高合法候选供给率，真正的算法发现仍主要发生在外部进化搜索中。

核心方法：

Validity-conditioned、paired、uncertainty-aware 的候选—父代训练信号，而不是继续堆叠 rank、novelty、operator credit 等经验项。

Operator scheduling 应暂时降为二级贡献或分析项，除非它能在标准 adaptive operator selection 基线上展示明确优势。

一、第一轮：AHD 文献与新颖性审查

1.1 当前领域已经比前几轮讨论时更拥挤

CALM 已经明确占据：

local 7B model + GRPO + AHD online co-evolution

这个位置。其论文和仓库都强调在单张 24GB GPU 上使用量化 Qwen2.5-7B，并称本地配置约占 22GB 显存。 [arXiv +1](#)


但“22GB 显存可运行”只描述峰值显存需求，不等于总成本低。总成本还包括：

LLM generation + candidate execution + GRPO updates + repeated evaluations + multip

因此，未来不能简单沿用 CALM 的“本地低成本”叙事，而应明确区分：

- 显存门槛；
- GPU-hours；
- candidate evaluation time；
- 总 completions；
- 总 valid evaluations；
- 达到目标性能所需成本。

LLM4AD 本身已经是成熟平台，提供统一方法、任务和 LLM 接口，以及多进程、安全评估、日志、GUI、resume 等功能；因此平台功能和 EoH 基础设施不能算你们贡献。



1.2 近期 AHD 的创新维度已经快速扩张

2025—2026 年的近期工作已经覆盖了许多此前可能被视为创新点的方向：

工作	已覆盖的方向
PathWise	将 heuristic generation 建模为序列决策，使用 policy、world model、critic 和搜索轨迹记忆
CoEvo-AHD	双种群协同演化、pairwise scoring、joint crossover、tool library
ReVEL	performance-profile grouping、多轮 reflection、meta-controller
MeEvo	natural evolution 与 metacognitive evolution 双层耦合
DSEvolve	quality-diverse portfolio、MAP-Elites、在线快速部署
Clade-AHD	clade-level Bayesian beliefs、Thompson sampling
EoH-S	complementary heuristic set、set-level population management
Hercules	core abstraction 和 performance prediction，减少昂贵评估
DASH	trajectory-aware evaluation、runtime schedule、profile retrieval
HeurAgenix	contrastive evolution、heuristic selector、POR/CPR、TTS

这些工作说明，单纯提出：

- 新 operator；
- 多几个 prompt；
- 自适应 mutation/crossover 权重；
- reflection；
- heuristic archive；
- profile retrieval；
- trajectory metric；

都很难构成足够强的新颖性。



第一轮结论

最稳的新颖性不是再提出一种搜索控制机制，而是研究 online AHD post-training 的信号归因。

当前领域普遍回答的是：

如何更好地搜索 heuristic？

你们可以回答：

搜索轨迹回流训练模型时，模型究竟学到了什么？如何证明它学到的是 heuristic quality，而不是只学会输出合法代码？

这是更清晰的研究空位。

1.3 Operator scheduling 本身不是新问题

在传统 evolutionary computation 和 metaheuristics 中，adaptive operator selection 已经有大量先例：

- 把 operator 看成 multi-armed bandit 的 arm；
- 用 dynamic Thompson sampling 适应 non-stationary operator reward；
- 用 population convergence/diversity/feasibility 作为状态；
- 用深度强化学习选择 operator；
- 在 ALNS 中把 operator selection 建模为 MDP。

因此，简单的：

$$c_{o,t} = (1 - \alpha)c_{o,t-1} + \alpha r_{o,t}$$

再加：

$$q_t(o) = \text{softmax}(c_{o,t})$$

很容易被审稿人视为已有 AOS 方法在 LLM4AHD 上的应用，而不是核心创新。  arXiv +2

对现有方案的修正

Operator scheduling 不应再默认为第二主创新。

它只有在满足以下条件时才值得进入主文：

1. 证明 operator 确实产生不同类型的 post-training signals；
2. 证明差异不能由 valid rate 单独解释；
3. 与 sliding-window UCB、dynamic Thompson sampling、valid-rate scheduler、raw-reward scheduler 比较；
4. 证明 post-registration signal yield 显著提升；
5. 最终改善 conditional quality 或 sample efficiency。

否则应只作为：

operator-policy coupling analysis

放在实验分析或附录。

二、第二轮：LLM 后训练与 GRPO 机制审查

2.1 “训练后性能提高”并不能识别模型学到了什么

近期 RLVR 研究发现，在 Qwen2.5-Math-7B 上，即使使用 random reward、format reward 或错误标签，RL 也可能带来接近 ground-truth reward 的性能提升。这个结果具有模型家族依赖性，并不能直接证明 CALM 的 Qwen2.5-7B-Instruct 也存在同样行为，但它明确说明：

观察到 RL 后 benchmark 提升，并不能自动识别真正起作用的训练信号。

这正是你们做 validity-only、performance-shuffled、repair baseline 的理论动机。 

因此，不能从：

CALM-GRPO end-to-end performance > no-GRPO

直接推出：

模型内化了 heuristic-design knowledge

也可能是：

模型输出形式更稳定

或：

预训练已有代码模式被激活

或：

搜索器获得更多可评估候选

2.2 Signal bootstrapping 是合理问题，但不应被包装成大量机制

DeepSeek-R1-Zero 表明纯 RL 可以诱导出推理行为，但也出现可读性差、语言混杂等问题；正式 R1 因此使用 cold-start data 和多阶段训练。这个现象支持一个一般判断：

当模型初始行为距离目标协议过远时，纯 outcome RL 未必能稳定地产生目标能力。

 arXiv

迁移到 AHD，本地小模型的最初瓶颈可能不是“不会设计 heuristic”，而是：

- 无法正确输出函数；
- 无法保持签名；
- 无法遵循 operator 指令；
- 无法避免随机和泄漏；
- 无法稳定完成局部代码编辑。

这使得早期 GRPO group 中真正可比较的 valid samples 数量很低。

设单个 completion 满足 contract 和 validity 的概率为 p ，每组生成 K 个 completion，则至少有两个 valid completion 的概率为：

$$P(N_v \geq 2) = 1 - (1 - p)^K - Kp(1 - p)^{K-1}$$

以 $K = 8$ 为例：

valid probability p	至少两个 valid 的概率
0.05	5.7%
0.10	18.7%

valid probability p	至少两个 valid 的概率
0.20	49.7%
0.30	74.5%

这说明，如果初始 valid rate 只有 10%，超过 80% 的 group 连两个可比较的合法候选都没有。此时“heuristic-quality GRPO”在统计上几乎无法有效工作。

第二轮结论之一

Signal bootstrapping 是真实问题，但不需要因此引入一整套复杂 curriculum、SFT、repair、operator difficulty scheduler。

更简洁的处理是：

1. 主设置保持 no-SFT fair core；
2. 对非法输出保留分层 reward；
3. 加一个强 baseline：constrained template / deterministic repair；
4. 只有当 group 中存在足够 valid candidates 时，才启用 quality preference；
5. protocol-SFT 只做 secondary baseline。

2.3 GRPO 低方差问题不是本项目可以独占的新颖性

近期 MDP-GRPO 已经系统研究了 discrete、low-dispersion reward 下的：

- zero-variance collapse；
- low-variance amplification；
- mean-centering blindness。

GRPO 的 U-statistic 分析和 normalization 研究也已经讨论 group size、finite-sample error、within-prompt variance 与收敛的关系。 [arXiv +2](#)

因此，不能把论文贡献写成：

我们首次发现 AHD-GRPO 有 zero-variance 问题。

更合理的表述是：

AHD 提供了一个特有的 low-dispersion 场景：大多数输出被 validity gate 阻断，而真实 heuristic improvement 又稀疏。我们研究如何将执行器产生的 parent-candidate evidence 转化为可信的 group-relative signal。

一个重要修正

此前方案希望通过 rank bonus、novelty bonus 主动增加 reward variance。严格审查后，这个做法风险较高：

Reward variance 不是越大越好。

如果多个候选在 evaluator 噪声范围内无法区分，强行给它们 rank reward，可能只是把 evaluator noise 转成错误梯度。

HeurAgenix 的 POR 恰恰是压缩 positive group 内部差异，而不是无限放大细粒度排名。

📄 Yang 等 - 2025 - HeurAgenix Leve...

因此应从：

如何强制制造 reward variance?

转为：

哪些 parent-candidate 差异有足够证据支持训练？哪些应当保持 neutral?

2.4 “模型坍缩”不是最准确的理论框架

泛化的 recursive synthetic-data model collapse 与 AHD 有明显区别：

- AHD 有外部程序执行器；
- 有真实任务实例；
- 有 objective performance；
- 有 population selection；
- 不是无验证地反复训练模型生成文本。

因此，不建议把主问题描述成：

CALM 会导致 model collapse。

更准确的术语是：

- policy-induced sampling bias；
- adaptive data collection；
- on-policy distribution shift；
- search-conditioned supervision；
- performative feedback；
- trajectory overfitting。

“模型坍缩”可以作为弱类比，但不应作为理论主轴。

三、第三轮：因果、统计与实验有效性审查

这一轮对前面方案做出了最重要的修正。

3.1 收益分解公式是描述性恒等式，不是因果分解

此前使用：

$$\mathbb{E}[\Delta^+] = P(C)P(V | C)P(\Delta > 0 | C, V)\mathbb{E}[\Delta | C, V, \Delta > 0]$$

需要给出严格定义。

令：

$$Y = \mathbf{1}[C = 1]\mathbf{1}[V = 1]\max(\Delta, 0)$$

则：

$$\mathbb{E}[Y] = P(C = 1)P(V = 1 | C = 1)P(\Delta > 0 | C, V)\mathbb{E}[\Delta | C, V, \Delta > 0]$$

这是一个精确的 hurdle decomposition。

但它只能说明观察到的 useful-candidate yield 如何分解，不能自动证明：

提升的多少百分比因果上来自 validity。

原因是：

- 训练同时改变 validity 和 valid-output distribution；
- parent population 也在变化；
- prompt distribution 也在变化；
- operator choice 也在变化。

因此论文中应明确称其为：

descriptive decomposition / operational decomposition

而不是：

causal mediation decomposition。

3.2 Same-valid-budget 很重要，但不能被解释为纯粹的因果直接效应

Same-valid-budget 比较：

$$Best_{\theta}(K_{\text{valid}})$$

具有明确的工程意义：

如果两个方法都向搜索器提供同样数量的合法候选，哪个方法产生的候选更好？

但 validity 是训练后的 post-treatment variable。条件化在：

$$V = 1$$

可能引入 selection bias：

- base model 和 trained model 进入 valid set 的候选类型不同；
- 同一个潜在 candidate 在不同模型下不存在一一对应关系；
- conditioning on validity 可能改变候选分布组成。

所以 same-valid-budget 应被写成：

resource-normalized diagnostic

而不是：

训练对 heuristic quality 的无偏因果直接效应。

为增强证据，必须增加两个控制

第一，**constrained-valid generation**：

- 固定代码 skeleton；
- 只让模型生成函数体或表达式；

- 或使用统一 deterministic repair;
- 尽量把两类模型都放到相同可执行空间。

第二，**fixed prompt/parent bank**：

- 固定 prompts;
- 固定 parents;
- 固定实例 batch;
- 固定 temperature、top-p、completion length;
- 不允许 population 动态改变 prompt。

只有这样，才能更接近比较模型本身的 proposal distribution。

3.3 Candidate 数量不是独立样本数

同一 run、同一 prompt、同一 parent 下生成的 candidates 高度相关。不能把几千个 candidate 当成几千个独立实验样本。

推荐统计层次：

run $\rightarrow$ prompt/parent $\rightarrow$ completion $\rightarrow$ instance

主统计单位应是：

- run;
- 或 prompt cluster;

而不是 candidate。

推荐：

- run-level confidence interval;
- cluster bootstrap;
- hierarchical bootstrap;
- mixed-effects logistic/linear model;
- prompt 和 run 作为 random effects。

例如 validity 可建模为：

$$\text{logit } P(V_{rpi} = 1) = \beta_0 + \beta_1 \text{Treatment}_r + u_r + v_p$$

conditional improvement 也应使用 cluster-aware 估计。

3.4 使用相同实例 batch 和 common random numbers

候选 h_c 和 parent h_p 应在相同实例 batch 上评估。

令：

$$D_j = S(h_c, x_j) - S(h_p, x_j)$$

则：

$$\text{Var}(D) = \text{Var}(S_c) + \text{Var}(S_p) - 2 \text{Cov}(S_c, S_p)$$

在相同实例和相同随机种子上评估，会增加正协方差，从而降低差值方差。

这比：

- candidate 在一批实例评估；
- parent 在另一批实例评估；

更适合构造可靠 reward。

DASH 已经采用 candidate 与 direct parent 在同一 batch 上比较，并使用 margin 处理随机轨迹，这说明 paired comparison 在 LHD 中具有直接先例；但 DASH 用于 solver selection，不是模型 GRPO reward。 [Wang 等 - 2026 - Rethinking LLM...](#)

3.5 搜索关注尾部，不只关注均值

Evolutionary search 最终依赖的是 candidate distribution 的高质量尾部。

因此 search-free 模型评估不能只报告：

$$\mathbb{E}[\Delta \mid V]$$

还应报告：

- $P(\Delta > 0 \mid V)$;
- improvement magnitude;
- best-of- K valid quality;
- 90/95 percentile;
- candidate-quality CDF;
- parent win probability;
- diversity-adjusted best-of- K 。

一个模型即使平均 candidate 不强，但高质量尾部更厚，也可能显著改善搜索。

3.6 Performance-shuffled control 必须正确实现

不能全局随机打乱 performance reward。正确方式是：

- 只在同一 prompt/group 内；
- 只在 valid candidates 中；
- 保留 validity reward；
- 保留 reward marginal distribution；
- 保留 positive/negative 数量；
- 只破坏 candidate 与 performance 的对应关系。

否则，global shuffle 会同时改变：

- reward scale；
- task composition；
- prompt difficulty；
- valid/invalid composition；

导致无法归因。

四、第四轮：方法设计与复杂度审查

4.1 此前宽方案确实仍然像工程堆叠

此前主方案包括：

- signal decomposition;
- contract gate;
- validity gate;
- curriculum;
- rank reward;
- novelty reward;
- contrastive reward;
- operator scheduling;
- post-registration credit;
- protocol-SFT;
- repair;
- LoRA drift;
- reuse/archive。

即使每个组件都有道理，组合起来仍会产生三个问题：

第一，审稿人难以判断核心创新是什么。

第二，消融数量爆炸。

第三，任何性能提升都可能被归因于更多机制和更多计算。

审查结论

AAAI 主线应压缩为：一个现象 + 一个方法 + 一套严格评估。

现象：

validity-mediated search amplification。

方法：

validity-conditioned、paired、uncertainty-aware quality signal。

评估：

fixed prompt bank + same-valid diagnostic + search-free generation + constrained-valid control。

4.2 Generic contrastive/group reward 仍然不够强

简单地将候选分成：

$$Y_+, Y_-, Y_{\text{err}}$$

然后按 rank 给 reward，与 HeurAgenix 的 POR 思路距离较近。HeurAgenix 已经明确针对 noisy rollout values，压缩 positive/negative group 内部差异并放大组间 margin；其 Qwen-

7B selector 实验中，POR+CPR 明显优于 raw model 和 vanilla GRPO。

📄 Yang 等 - 2025 - HeurAgenix Leve...

因此，你们的方法不能只是：

把 CALM reward 改成正负集合。

真正有区分度的方法应利用 AHD generated-program 场景独有的信息：

- candidate 与直接 parent 的配对关系；
- 同实例上的 per-instance delta；
- evaluator uncertainty；
- code validity gate；
- duplicate behavior；
- search registration。

4.3 建议的核心方法：VC-PAIR

暂定名称：

Validity-Conditioned Paired Preference GRPO

简写：

VC-PAIR

名称后续可以调整。

第一步：Contract 和 validity gate

候选必须满足：

$$C_i = 1, \quad V_i = 1$$

否则使用 CALM-style hierarchical validity penalty。这里不需要推翻 CALM 的 infeasible hierarchy，可以直接将其作为合理基础。

第二步：Candidate-parent paired evaluation

对 candidate h_i 和其 direct parent h_p ，在相同 batch：

$$B = \{x_1, \dots, x_m\}$$

上评估。

定义 oriented per-instance improvement：

$$d_{ij} = U(h_i, x_j) - U(h_p, x_j)$$

其中 U 统一定义为越大越好。

第三步：估计置信区间或胜率

计算：

$$\hat{\mu}_i = \frac{1}{m} \sum_{j=1}^m d_{ij}$$

并通过 paired bootstrap、paired t -interval 或 sign-based 方法得到：

$$[L_i, U_i]$$

也可以估计：

$$p_i^+ = P(\mu_i > \delta \mid d_{i1:m})$$

其中 δ 是 minimum meaningful improvement。

第四步：三态质量信号

$$r_i^{quality} = \begin{cases} +a\phi(L_i - \delta), & L_i > \delta \\ -b\phi(-U_i - \delta), & U_i < -\delta \\ 0, & \text{otherwise} \end{cases}$$

也就是：

- 有充分证据优于 parent：positive；
- 有充分证据差于 parent：negative；
- 无法可靠区分：neutral。

然后再加：

- confident frontier bonus；
 - duplicate-profile penalty；
 - exact-copy penalty。
-

第五步：不要强制给 ambiguous candidates 排名

如果两个候选的差异落在 evaluator noise 内，就不应为了降低 zero-variance 而硬分高低。

这是与此前 rank/novelty 方案的关键区别：

Zero reward variance 有时代表 evaluator 没有足够证据，而不是一定代表训练失败。

真正的解决方案可能是：

- 增加评估样本；
- 使用 paired evaluation；
- 改进数据采样；
- 或保持 neutral；

而不是强行制造虚假的 dense reward。

4.4 该方法相对已有工作的区别

相对 CALM:

- CALM 使用 aggregate parent-relative improvement;
- VC-PAIR 使用同实例的 paired delta;
- 加入 uncertainty / confidence margin;
- 区分 confident improvement 和 evaluator-indistinguishable candidate。

相对 HeurAgenix:

- HeurAgenix 处理有限 heuristic pool 中的 selector action;
- VC-PAIR 处理开放式 generated programs;
- 额外处理 validity、runtime failure、duplicate behavior 和 direct-parent code generation。

相对 DASH:

- DASH 用 paired/margin 选择 solver;
- VC-PAIR 将 paired evidence 转化为 LLM post-training reward;
- 不优化 solver runtime schedule。

在本轮覆盖的主流近期 AHD 文献中, 未见将 **generated-program validity gate**、**same-batch parent pairing**、**uncertainty-calibrated preference reward** 组合用于在线 AHD-GRPO 的明确方法; 但这仍需在正式 related-work 阶段继续检索, 不能直接声称“首次”。

五、第五轮: Operator scheduling 专项红队审查

5.1 结论: 先降级, 不要删除日志

Operator scheduling 的概念价值仍然存在:

$$D_t = \sum_o q_t(o) D_t^o$$

不同 operator 的确可能产生不同的:

- contract success;
- valid rate;
- quality improvement;
- duplicate profile;
- reward dispersion。

但作为 AAAI 主创新, 目前风险过高:

1. AOS 已有大量传统工作;
2. PathWise、ReVEL、MeEvo、Clade-AHD 已覆盖动态搜索控制;
3. 你们需要额外实现和消融;
4. 容易造成论文主线分散;
5. 距离截止时间太短。

5.2 当前合理处理

主实验仍应记录 operator-level 数据:

$$P(C = 1 \mid o)$$

$$P(V = 1 \mid C, o)$$

$$P(\Delta > 0 \mid C, V, o)$$

$$\text{Var}(r \mid o)$$

$$\text{duplicate_rate}(o)$$

但暂不默认实现复杂 scheduler。

只有 pilot 显示：

- operator conditional quality 差异大；
- 差异随搜索阶段变化；
- fixed schedule 明显浪费预算；

才进入 P1。

5.3 若保留，必须使用标准 AOS baseline

至少比较：

1. fixed cycle；
2. uniform；
3. valid-rate scheduler；
4. raw-reward EMA；
5. sliding-window UCB；
6. dynamic Thompson sampling；
7. proposed post-registration scheduler。

否则，审稿人很容易指出：

该方法只是已有 adaptive operator selection 的简化版本。

第五轮结论

Operator scheduling 从原来的“核心创新 3”降为：

可选 **secondary contribution / operator-level analysis**。

这是本轮审查中最重要的删减之一。

六、第六轮：系统成本、泛化、复用与 AAI 红队审查

6.1 本地 22GB 不是完整价值主张

CALM 的官方描述是：

- 单张 24GB GPU 可运行；
- 本地量化 Qwen2.5-7B；
- 约 22GB GPU memory。 [GitHub](#)

但你们应明确指出：

$$\text{memory footprint} \neq \text{total adaptation cost}$$

总成本至少需要报告：

$$C_{\text{total}} = C_{\text{generation}} + C_{\text{evaluation}} + C_{\text{GRPO}} + C_{\text{failed candidates}} + C_{\text{repeated runs}}$$

若某任务中的 heuristic evaluation 很昂贵，模型训练本身可能不是主要成本。

6.2 训练出的模型应被定义为 proposal policy

最稳的模型定位是：

AHD proposal policy

而不是：

universal heuristic designer。

它可能学到三层东西：

层 1: Protocol skill

$$P(C = 1), P(V = 1) \uparrow$$

跨任务可能部分复用。

层 2: Problem-family proposal prior

$$P(\Delta > 0 \mid C, V) \uparrow$$

可在同问题族跨规模复用。

层 3: Search-specific trajectory memory

只对原搜索轨迹和 parent distribution 有效，几乎不能独立复用。

论文真正需要判断训练落在哪一层。

6.3 参数复用和系统资产复用必须分开

未来复用实验至少分三种：

Parameter-only transfer

只加载 LoRA / adapter：

- 不加载 archive；
- 不加载原 population；
- 不加载 operator credit；
- 使用新 seed 和新 instances。

这才接近测试模型是否内化 problem-family prior。

Archive-only transfer

只加载强 heuristic / parent library，不加载 adapter。

测试：

复用收益是否实际上来自搜索资产，而不是模型参数。

Full-system transfer

加载：

adapter + archive + operator prior

测试系统部署价值。

如果不拆开，就不能声称“模型可复用”。

6.4 训练成本需要摊销分析

设单次训练成本为：

$$C_{\text{train}}$$

每次后续搜索节省：

$$S_{\text{future}}$$

则复用 m 次后的净收益：

$$\text{NetGain}(m) = mS_{\text{future}} - C_{\text{train}}$$

Break-even：

$$m^* = \frac{C_{\text{train}}}{S_{\text{future}}}$$

如果一个 adapter 只能在一次搜索中使用，其现实价值可能很弱。若它能在同问题族的多次任务中减少 query/evaluation cost，则“本地训练”才有合理意义。

DASH 通过 profile-specific archives 和 PLR 来减少 distribution shift 下的重新适配，这也说明单一 solver 或单一模型参数通常不会自动跨分布泛化。

📄 Wang 等 - 2026 - Rethinking LLM-...

6.5 AAAI 时间约束

AAAI-27 官方时间为：

- 2026 年 7 月 21 日摘要截止；
- 2026 年 7 月 28 日全文截止；
- 2026 年 7 月 31 日补充材料与代码截止；
- 截止时间均为 UTC-12。

AAAI

按当前 7 月 10 日计算，摘要约剩 11 天，全文约剩 18 天。

第六轮结论

当前没有时间支持：

- 三个核心方法模块；
- 四个以上任务；
- 大量 operator scheduler；
- SFT 和 no-SFT 双主线；
- 完整 reuse 系统；
- 全面复现 DASH、HeurAgenix 和所有强在线模型。

必须采用：

One phenomenon + one method + one rigorous protocol

七、六轮审查后的统一结论

7.1 应保留的核心内容

核心现象

Validity-mediated search amplification

核心方法

Validity-conditioned paired uncertainty-aware reward

核心实验协议

fixed prompt bank + same-query + same-valid + search-free + constrained-valid control

7.2 应降级的内容

原计划内容	审查后定位
Operator scheduling	二级分析，结果强时再进入主文
Protocol-SFT	可选 baseline
Repair	必须 baseline，但不是创新
Curriculum	隐含在 signal availability gate 中，不单独包装
Novelty bonus	默认删除或极弱使用
Rank bonus	不作为核心；防止放大噪声
LoRA drift	附录或未来工作
Collapse	删除

原计划内容	审查后定位
tLDR / runtime schedule	不进入主线
Profile retrieval	不进入主线
Cross-task universal model	删除该 claim

八、最终推荐的 AAAI 主线

8.1 推荐题目

Search-to-Signal: Validity-Conditioned Paired Post-Training for LLM-based Automatic Heuristic Design

备选：

Learning Beyond Valid Code: Paired Post-Training Signals for LLM-based Heuristic Design

更偏诊断的备选：

Does Online RL Teach Heuristic Design or Merely Valid Code?

第三个标题略具对抗性，更适合备选路线而非主方法论文。

8.2 核心问题

在线 AHD-RL 的端到端提升，究竟来自模型生成更多合法候选，还是来自合法候选内部质量分布的真正改善？

8.3 核心方法 Claim

We construct post-training signals from validity-conditioned, paired candidate-parent evidence under shared evaluation batches. Rather than forcing fine-grained ranks from noisy endpoint scores, our method assigns positive, negative, or neutral preferences according to statistically supported performance differences.

中文：

我们在控制代码合法性的前提下，基于候选与直接父代在相同实例批次上的配对证据合成训练信号。与从 noisy endpoint scores 中强制生成细粒度排名不同，我们只在性能差异得到统计证据支持时产生正负偏好，其余候选保持 neutral。

8.4 推荐贡献点

Contribution 1: Validity-mediated search amplification diagnosis

提出并验证：

$\text{end-to-end gain} = \text{validity yield} + \text{conditional quality} + \text{external search amplification}$

其中该式是描述性分解，不宣称因果中介。

Contribution 2: VC-PAIR reward

- 利用：
- contract/validity gate；
 - same-batch candidate-parent delta；
 - uncertainty/confidence；
 - positive/negative/neutral preference；

构造更加可靠的 GRPO signal。

Contribution 3: Controlled internalization protocol

- 提出：
- fixed prompt/parent bank；
 - same-valid diagnostic；
 - constrained-valid generation；
 - search-free model comparison；
 - parameter-only family transfer。

这套协议用于判断模型是否真正获得了 problem-family heuristic proposal prior。

Operator analysis可作为实验贡献，不默认作为主方法贡献。

九、最终实验矩阵

Variant	训练	合法性处理	性能信号	目的
A0 Base + EoH	否	原始	无	基础搜索
A1 Base + repair/template + EoH	否	强制/修复	无	判断合法率提升是否无需训练
A2 CALM-style GRPO	是	分层 penalty	aggregate parent-relative	强 RL baseline
A3 Validity-only GRPO	是	分层 penalty	无	估计 validity contribution
A4 Performance-shuffled GRPO	是	同 A2	group 内打乱	检验性能信号对应关系
A5 VC-PAIR GRPO	是	validity gate	paired uncertainty-aware	主方法

Variant	训练	合法性处理	性能信号	目的
A6 VC-PAIR + scheduler	是	同 A5	同 A5	仅 P1 可选

十、实验实施细节

10.1 Fixed prompt bank

建立离线 prompt/parent bank：

- 从 no-training search 中收集；
- 冻结 parent code；
- 冻结 prompt；
- 不让测试模型改变 population；
- 每个模型在同样 prompt 上生成相同 K 个 completion；
- 使用相同 decoding 参数。

这样测到的更接近模型 proposal ability。

10.2 Search-free 核心指标

主指标：

$$P(\Delta_p > 0 \mid C, V)$$

$$E[\Delta_p \mid C, V, \Delta_p > 0]$$

$$BestOfK_{\text{valid}}$$

$$P(\text{candidate beats parent})$$

辅助指标：

- valid rate；
- contract rate；
- duplicate profile；
- code diversity；
- score CDF。

10.3 Same-valid curve

不要只取一个任意 K 。

画：

$$Best(k), \quad k = 1, \dots, K_{\text{max}}$$

并报告：

$$AUC_{\text{valid}} = \frac{1}{K_{\text{max}}} \sum_{k=1}^{K_{\text{max}}} \text{Best}(k)$$

同时报告：

QueriesToKValid

避免某些方法根本无法达到 K_{max} 时产生 censoring 偏差。

10.4 统计设计

推荐：

- 主任务：TSP + OBP；
- pilot: 3 seeds；
- 主结果：至少 5 seeds；
- 每个模型使用相同 prompt bank；
- candidate-parent 使用相同 instance batch；
- run/prompt cluster bootstrap；
- 报告 effect size 和 95% CI；
- 不把 candidate 当独立样本。

10.5 成本报告

至少报告：

- total completions；
- total valid completions；
- total evaluations；
- evaluator wall-clock；
- GRPO GPU-hours；
- peak GPU memory；
- total GPU-hours；
- queries-to-target；
- valid-evals-to-target；
- parameter-only reuse saving。

十一、备选论文路线

路线 A：主方法论文

适用条件：

- VC-PAIR 显著提高 conditional quality；
- same-valid 曲线更好；
- search-free improvement 存在；
- repair baseline 无法解释全部收益。

题目：

路线 B：机制分析论文

适用条件：

- validity-only 几乎复现 CALM 增益；
- same-valid 优势消失；
- search-free 无质量提升；
- repair baseline 接近 GRPO。

题目：

Does Online RL Teach Heuristic Design or Merely Valid Code?

贡献：

- 揭示 validity-mediated search amplification；
- 建立 controlled evaluation protocol；
- 给出 AHD-RL 设计建议。

路线 C：本地模型摊销论文

适用条件：

- parameter-only adapter 在同问题族迁移有效；
- 训练后后续搜索显著减少 query/eval；
- 单次搜索提升一般，但多次复用收益明显。

题目：

Amortizing Local Proposal Policies for LLM-based Heuristic Design

路线 D：Operator/data-acquisition 论文

只在以下条件下使用：

- operator conditional quality 差异显著；
- 动态变化明显；
- standard AOS baselines 被击败；
- scheduler 提升 quality，而非只提高 valid rate。

否则不建议单独成文。

十二、风险—收益最终矩阵

方向	学术收益	实验风险	新颖性风险	当前建议
Validity-mediated diagnosis	高	中	低	必做

方向	学术收益	实验风险	新颖性风险	当前建议
VC-PAIR reward	高	中	中	主方法
Same-valid/search-free protocol	高	低中	低	必做
Operator scheduling	中	高	高	降级
Protocol-SFT	低中	中	高	baseline
Repair/template	高防守价值	低	无	必做 baseline
LoRA drift	中	高	中	暂停
Collapse	低	中	高	删除
Cross-task generalization	高但不现实	很高	中	不主打
Same-family parameter transfer	中高	中	中	有余力再做
Archive/system reuse	实用价值高	中	与 DASH 重叠	分开报告

十三、AAAI 红队预审

13.1 对此前宽方案的预审

维度	评分 / 10	主要问题
新颖性	5	reward、operator、SFT 均有邻近工作
重要性	7	AHD-RL 信号问题真实
技术严谨性	4	same-valid 被过度解释，统计设计不足
清晰性	4	模块过多
可完成性	3	截止时间过近
综合	Weak Reject 风险较高	工程堆叠

13.2 对收窄方案的预审

维度	评分 / 10	改善
新颖性	7	明确针对 signal attribution 与 paired reward

维度	评分 / 10	改善
重要性	7	直接回答 AHD-RL 是否内化能力
技术严谨性	7	paired/common-batch/uncertainty/controlled tests
清晰性	7	一个现象、一个方法
可完成性	6	两任务、核心控制可完成
综合	Borderline Accept 到 Accept 取决于结果	值得推进

这不是实际审稿评分，而是内部红队估计。

十四、接下来 18 天的执行顺序

7 月 10—12 日：基础设施

完成：

- candidate-level logging；
- group-level reward std；
- exact CALM-style reward；
- validity-only reward；
- within-group performance shuffle；
- repair/template baseline；
- fixed prompt bank。

7 月 13—15 日：判别性 pilot

在 TSP 和 OBP 小设置上跑：

- A0—A5；
- 3 seeds；
- same-query；
- same-valid；
- search-free。

7 月 15 日做第一次硬决策：

- conditional quality 有提升：走方法路线；
- 只有 validity 提升：走诊断路线。

7 月 16—20 日：主实验

- 扩展至 5 seeds；
- 完成 cluster-aware CI；
- 完成 paired reward；
- 准备主图和摘要。

7 月 21 日：提交摘要

摘要不得承诺未验证的 operator scheduler 或跨任务泛化。

7 月 22—25 日：补充结果

优先级：

1. strong repair baseline；
2. parameter-only same-family transfer；
3. 当前 frontier online model 的 search baseline；
4. operator-level analysis。

7 月 26—28 日：全文收口

不再添加新模块。

十五、最终 Go / No-Go 条件

继续方法论文路线

至少应满足三项：

1. VC-PAIR 显著提高：

$$P(\Delta > 0 \mid C, V)$$

2. Same-valid AUC 不劣于 CALM-style，最好明显更优；
 3. Search-free best-of- K valid quality 提升；
 4. Validity-only 和 repair baseline 不能解释全部收益；
 5. Performance-shuffled 显著弱于正确 performance pairing。
-

转机制分析路线

满足以下模式时应果断转向：

- CALM-style $\approx$ validity-only；
- CALM-style $\approx$ performance-shuffled；
- repair/template $\approx$ CALM-style；
- same-valid 无优势；
- search-free 无优势。

这不是实验失败，而是对 validity-mediated search amplification 的强证据。

删除 operator scheduling

如果：

- operator 差异主要来自 valid rate；
- standard AOS baseline 与 proposed scheduler 无差异；
- scheduler 不提高 conditional quality；

则从主文删除。

十六、最终审查结论

经过六轮独立审查，最重要的调整不是再增加机制，而是删减和重构。

此前方案：

decomposition + contrastive reward + operator scheduling + curriculum + SFT + reuse

仍然过于复杂。

当前推荐方案：

Validity-mediated diagnosis + VC-PAIR + controlled internalization evaluation

Operator scheduling降级。

SFT降级。

Novelty/rank bonus默认删除。

Collapse、LoRA gate、trajectory metric、profile retrieval不进入主线。

本地模型的价值被限定为：

problem-family AHD proposal policy

而非：

universal heuristic designer。

最终应回答的科学问题是：

在控制协议遵循、代码合法性和搜索预算之后，在线 RL 是否真的提高了本地模型生成高质量 heuristic 的条件概率和尾部质量？

如果答案是肯定的，VC-PAIR 可以构成一篇方法型 AAAI 论文。

如果答案是否定的，那么“当前 AHD-RL 主要通过合法性提升和外部搜索放大起作用”本身就是一项有价值、可验证、且比堆叠更多搜索机制更清晰的研究结论。